# LAB 03

## Thiết kế, huấn luyện và kiểm thử Tiny CNN

Mô hình CNN tự thiết kế trên Edge Impulse

Slide 04 · Cơ sở lý thuyết, quá trình thực hiện và kết quả

# Nội dung bài học

- Vì sao nhóm tự thiết kế CNN thay cho mạng có sẵn?
- Hiểu các tham số huấn luyện và nguyên nhân cần cải tiến mô hình.
- Theo dõi quá trình phát triển Tiny CNN từ V1 đến V5.
- Kiểm thử Float32 / INT8 và xuất mô hình phục vụ Lab 04.

# Dữ liệu dùng trong Lab 03

Tiếp tục dự án Brain_MRI_PYNQ_Z2 đã chuẩn bị ở Lab 02.

**4.955**

ảnh Training

**995**

ảnh Test giữ riêng

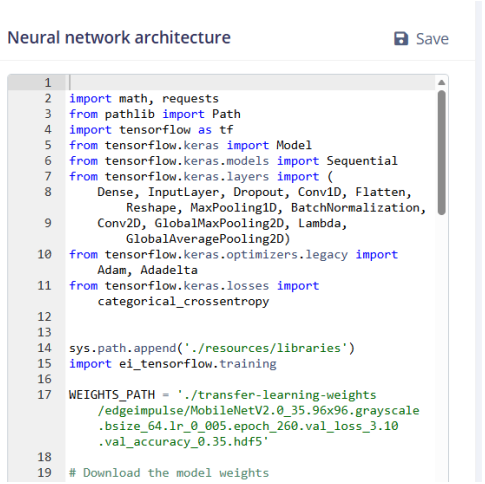
---

- Trong tập Training, Edge Impulse chia **3.964 ảnh để học** và **991 ảnh Validation**.
- Bốn nhãn: **glioma – meningioma – no_tumor – pituitary**.

Tập Test 995 ảnh không tham gia huấn luyện và lựa chọn mô hình.

# Keras Expert Mode là gì?

- Mở **Transfer Learning (Images)** trong Edge Impulse Studio.
- Chọn **Switch to Keras (expert) mode** để viết trực tiếp cấu trúc mạng.
- Dự án dùng Tiny CNN tự thiết kế, **không sử dụng trọng số MobileNetV2**.




Giao diện Keras Expert Mode trong Lab 03 (ảnh gốc).

# Các thuật ngữ CNN cần hiểu

- **Conv2D / filter**: bộ lọc học đặc trưng từ ảnh; số filter là số kênh đầu ra.
- **ReLU**: hàm kích hoạt giữ phản hồi dương và loại bỏ phần âm.
- **MaxPooling2D**: giảm kích thước không gian của đặc trưng.
- **Dense / Softmax**: tổng hợp đặc trưng và tạo điểm số cho bốn lớp.

Đây là các thành phần được sử dụng trong các phiên bản Tiny CNN của Lab 03.

# Tiny CNN V1 – mô hình khởi đầu

Đầu vào: ảnh Grayscale 64 × 64 × 1.

```
model = Sequential([
    InputLayer(input_shape=(64, 64, 1)),
    Conv2D(4, (3, 3), activation=None),
    ReLU(), MaxPooling2D((2, 2)),
    Conv2D(8, (3, 3), activation=None),
    ReLU(), MaxPooling2D((2, 2)),
    GlobalAveragePooling2D(),
    Dense(classes, activation='softmax')
])
```

Mã rút gọn từ cấu trúc V1 để minh họa trình tự các lớp; tên lớp được lược bỏ.

# V1 cho thấy điều gì?

**51,1%**

Validation Accuracy INT8

**1,15**

Validation Loss INT8

---

- Huấn luyện **20 epoch**, batch 32, learning rate 0,0005.
- Độ chính xác Validation còn thấp, nên mô hình ban đầu chưa phù hợp để sử dụng.

# V2 – tăng khả năng học đặc trưng

- Giữ Conv1 gồm **4 filters**; tăng Conv2 lên **16 filters**.
- Bổ sung **Conv3 có 32 filters** và dùng Flatten → Dense 32 → Dropout 0,2.
- Huấn luyện 40 epoch với Adam; batch 32, learning rate 0,0005.

---

**90,8%** Validation Accuracy INT8

Trên giao diện INT8: Validation Loss = 0,35; Weighted F1 = 0,91.

# V3 – nhận biết overfitting

Overfitting: mô hình khớp dữ liệu học tốt nhưng không tổng quát hóa tương ứng.

**99,75%**

Training Accuracy cao nhất

**92,03%**

Validation Accuracy cao nhất

---

– V3 thử thêm Conv4 (64 filters), Batch Normalization và Dropout 0,3.

– Checkpoint được khôi phục tại **epoch 12** theo Validation Loss.

Validation INT8 của V3: Accuracy 90,9%; Loss 0,24. Không dùng Training Accuracy 99,75% làm kết quả chung.

# Epoch, batch và learning rate

- **Epoch**: một lượt mô hình học qua dữ liệu huấn luyện.
- **Batch size**: số ảnh đưa vào tính toán trong mỗi lần cập nhật tham số.
- **Learning rate**: mức điều chỉnh tham số của mô hình sau mỗi bước tối ưu.
- **Adam**: thuật toán tối ưu được dùng trong các thử nghiệm của nhóm.

Giải thích cơ sở lý thuyết; các con số cụ thể của V5 được trình bày ở phần sau.

# Validation không giống Test

| Tập dữ liệu | Vai trò trong quá trình nghiên cứu |
|---|---|
| Training | Dùng để cập nhật trọng số của mạng CNN. |
| Validation | Theo dõi để lựa chọn mô hình và điều chỉnh huấn luyện. |
| Test | Giữ riêng và dùng đánh giá sau khi chọn mô hình. |

**Trong Lab 03:** 3.964 ảnh học, 991 ảnh Validation và 995 ảnh Test.

# V4 – nâng độ phân giải đầu vào

- Đổi Impulse từ **64 × 64** sang **96 × 96**, giữ Grayscale và Fit longest axis.
- **Chạy lại Generate Features** vì kích thước đặc trưng đã thay đổi.
- Bốn khối Conv2D có số filters **8 – 16 – 32 – 64**.
- V4 dùng Dense 64, Dropout 0,4 và tối đa 70 epoch.

---

**95,7%** Validation Accuracy INT8; **0,12** Validation Loss.

V4 có 127.556 tham số; checkpoint tốt nhất theo val_loss ở epoch 62.

# V5 – kiến trúc được lựa chọn

| Thành phần | Thiết kế Tiny CNN V5 |
|---|---|
| Input | 96 × 96 × 1, Grayscale |
| Conv1 + ReLU + Pool1 | 8 filters, 3 × 3; padding valid |
| Conv2 / Conv3 / Conv4 | 24 / 48 / 64 filters; kernel 3 × 3, same |
| Classifier | Flatten → Dense 64 → Dropout 0,35 → Softmax 4 |
| Training | Adam, batch 32, LR 0,0003; tối đa 80 epoch |

# Vì sao tập trung vào Conv1?

- Đầu vào của mạng V5 có kích thước **96 × 96 × 1**.
- Conv1 gồm **8 bộ lọc 3 × 3**, stride 1 và padding valid.
- ReLU được tách thành lớp riêng để thuận tiện khi triển khai phần cứng.
- Đầu ra Conv1 có kích thước **94 × 94 × 8**.

---

Số MAC Conv1 = 94 × 94 × 8 × 3 × 3 = **636.192**.

# Data augmentation giúp ích gì?

- **Augmentation** tạo biến thể ảnh trong quá trình huấn luyện nhằm đa dạng hóa dữ liệu học.
- V5 có xoay ảnh nhẹ, dịch chuyển và điều chỉnh độ sáng / tương phản.
- Trong code, các phép augmentation phụ thuộc chế độ **ENSURE_DETERMINISM**.

```
augmentation = tf.keras.Sequential([
    tf.keras.layers.RandomRotation(
        factor=0.012, fill_mode='constant'),
    tf.keras.layers.RandomTranslation(
        height_factor=0.03,
        width_factor=0.03, fill_mode='constant')
])
```

# V5 – các lớp tích chập trong Keras

Trích đoạn thiết kế Conv1 – Conv2 và ranh giới đưa sang FPGA.

```
model = Sequential([
    InputLayer(input_shape=INPUT_SHAPE, name='x_input'),
    Conv2D(8, (3, 3), strides=(1, 1),
        padding='valid', activation=None, name='conv1'),
    ReLU(name='relu1'),
    MaxPooling2D((2, 2), name='pool1'),

    Conv2D(24, (3, 3), padding='same',
        activation=None,
        kernel_regularizer=regularizer,
        name='conv2'),
    # Cac lop con lai xem Lab 03
])
```

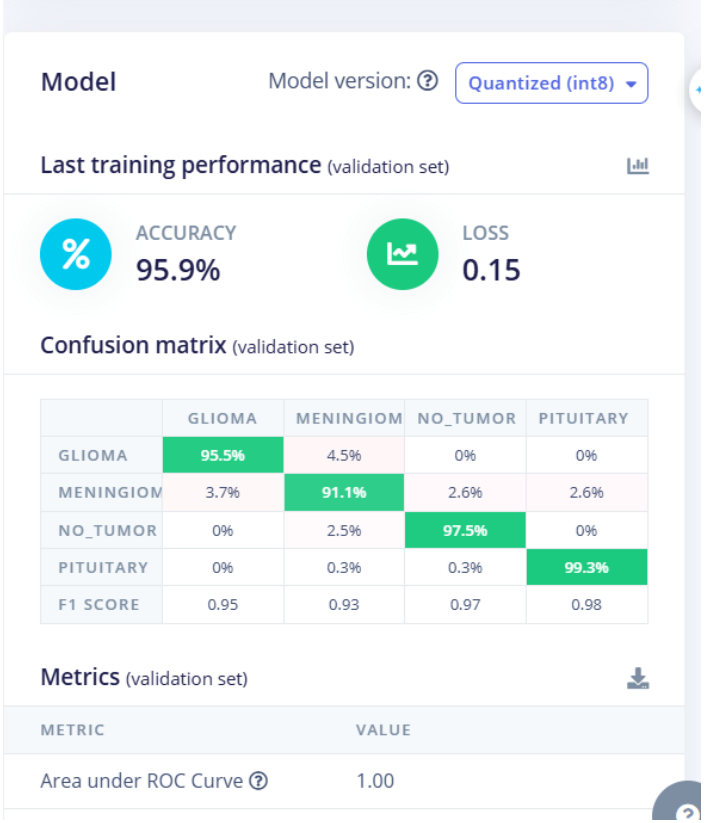
# Callbacks – kiểm soát quá trình học

- **ReduceLROnPlateau:** giảm learning rate khi val_loss không cải thiện.
- **EarlyStopping:** dừng quá trình học sau nhiều epoch không cải thiện.
- V5 theo dõi **val_loss**, có thể khôi phục trọng số tốt nhất.

```
tf.keras.callbacks.ReduceLROnPlateau(
    monitor='val_loss', factor=0.5,
    patience=5, min_lr=0.00001)
tf.keras.callbacks.EarlyStopping(
    monitor='val_loss', patience=16,
    restore_best_weights=True)
```

# Kết quả huấn luyện Tiny CNN V5

Ảnh thực tế từ kết quả Validation INT8 của Edge Impulse.



**Model** Model version: Quantized (int8)

**Last training performance** (validation set)

ACCURACY 95.9%

LOSS 0.15

**Confusion matrix** (validation set)

| | GLIOMA | MENINGIOM | NO_TUMOR | PITUITARY |
|---|---|---|---|---|
| GLIOMA | 95.5% | 4.5% | 0% | 0% |
| MENINGIOM | 3.7% | 91.1% | 2.6% | 2.6% |
| NO_TUMOR | 0% | 2.5% | 97.5% | 0% |
| PITUITARY | 0% | 0.3% | 0.3% | 99.3% |
| F1 SCORE | 0.95 | 0.93 | 0.97 | 0.98 |

**Metrics** (validation set)

| METRIC | VALUE |
|---|---|
| Area under ROC Curve | 1.00 |

## **95,9%** Accuracy INT8

Validation Loss = 0,15; Weighted F1 xấp xỉ 0,96. Đây chưa phải Test Accuracy.

# So sánh các phiên bản V1 – V5

| Phiên bản | Ảnh đầu vào | Val. Accuracy INT8 | Val. Loss INT8 |
|---|---|---|---|
| V1 | 64 × 64 × 1 | 51,1% | 1,15 |
| V2 | 64 × 64 × 1 | 90,8% | 0,35 |
| V3 | 64 × 64 × 1 | 90,9% | 0,24 |
| V4 | 96 × 96 × 1 | 95,7% | 0,12 |
| V5 | 96 × 96 × 1 | 95,9% | 0,15 |

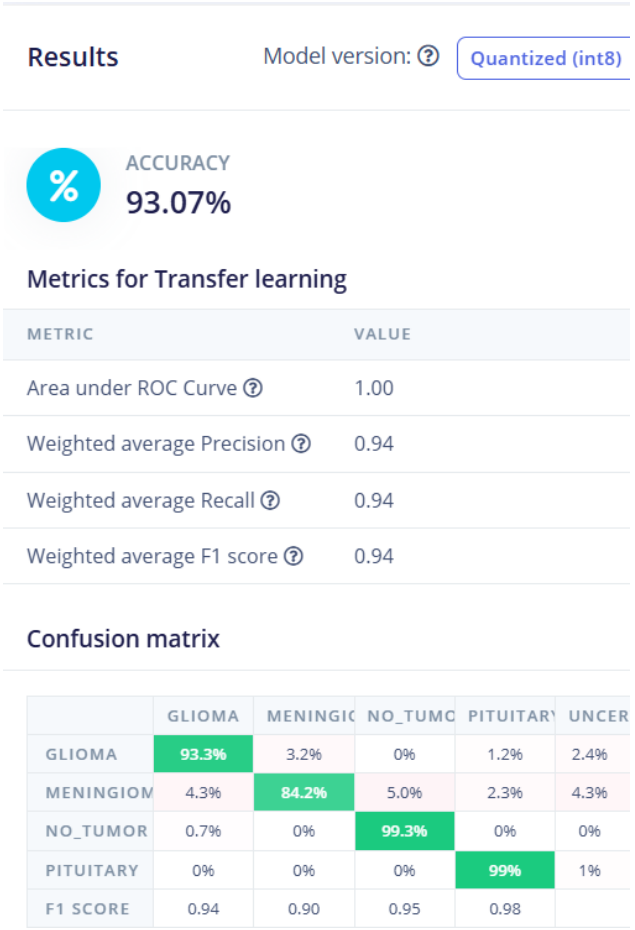
V5 tăng 0,2 điểm % Accuracy so với V4 nhưng có Loss cao hơn; không khẳng định tốt hơn trên mọi chỉ số.

# Đánh giá độc lập trên 995 ảnh Test

Edge Impulse → Model testing → Classify all.

| Chỉ số | Float32 | Quantized INT8 |
|---|---|---|
| Test Accuracy | 92,96% | 93,07% |
| Weighted Precision | 0,94 | 0,94 |
| Weighted Recall | 0,94 | 0,94 |
| Weighted F1-score | 0,94 | 0,94 |
| AUC hiển thị (làm tròn) | 1,00 | 1,00 |

# Kiểm thử INT8 trên giao diện Edge Impulse



Results

Model version: Quantized (int8)

ACCURACY
93.07%

Metrics for Transfer learning

| METRIC | VALUE |
|---|---|
| Area under ROC Curve | 1.00 |
| Weighted average Precision | 0.94 |
| Weighted average Recall | 0.94 |
| Weighted average F1 score | 0.94 |

Confusion matrix

| | GLIOMA | MENINGIC | NO_TUMC | PITUITARY | UNCER |
|---|---|---|---|---|---|
| GLIOMA | 93.3% | 3.2% | 0% | 1.2% | 2.4% |
| MENINGIOM | 4.3% | 84.2% | 5.0% | 2.3% | 4.3% |
| NO_TUMOR | 0.7% | 0% | 99.3% | 0% | 0% |
| PITUITARY | 0% | 0% | 0% | 99% | 1% |
| F1 SCORE | 0.94 | 0.90 | 0.95 | 0.98 | |

Ảnh kiểm thử INT8 trong Lab 03. Lần chạy đầu gặp lỗi Evicted / Job failed; lần chạy lại thành công.

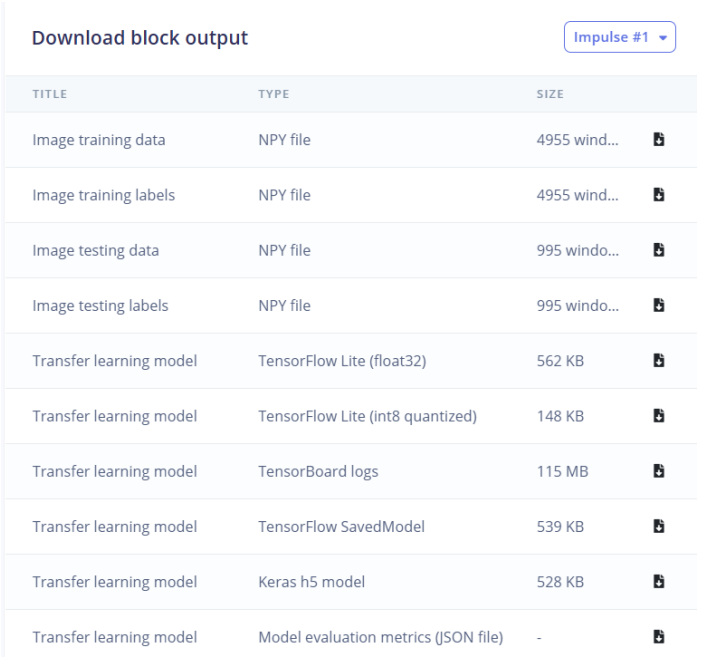
# Kết quả theo từng lớp ảnh

| Lớp MRI | Tỷ lệ nhận diện đúng trên giao diện INT8 |
|---|---|
| Glioma | 93,3% |
| Meningioma | 84,2% |
| No tumor | 99,3% |
| Pituitary | 99,0% |

**Meningioma** thấp nhất (84,2%). Confusion Matrix còn có cột Uncertain; không đồng nhất kết quả này với PYNQ-Z2.

# Xuất mô hình từ Edge Impulse

Dashboard → Download block output, chọn đúng Impulse #1.



**Download block output** — Impulse #1

| TITLE | TYPE | SIZE |
|---|---|---|
| Image training data | NPY file | 4955 wind... |
| Image training labels | NPY file | 4955 wind... |
| Image testing data | NPY file | 995 windo... |
| Image testing labels | NPY file | 995 windo... |
| Transfer learning model | TensorFlow Lite (float32) | 562 KB |
| Transfer learning model | TensorFlow Lite (int8 quantized) | 148 KB |
| Transfer learning model | TensorBoard logs | 115 MB |
| Transfer learning model | TensorFlow SavedModel | 539 KB |
| Transfer learning model | Keras h5 model | 528 KB |
| Transfer learning model | Model evaluation metrics (JSON file) | - |

- Keras H5 model.
- TensorFlow Lite float32.
- TensorFlow Lite int8 quantized.

# Ba mô hình cần giữ trong thư mục Source

```
Source/
    Dataset_MRI/
    check_duplicates.py
    verify_dataset.py
    tiny_cnn_v5.h5
    tiny_cnn_v5_float32.tflite
    tiny_cnn_v5_int8.tflite
```

Đổi tên tệp và phần mở rộng theo báo cáo; không sửa nội dung nhị phân của mô hình.

# Xác minh trọng số Conv1 cho Lab 04

| Đối tượng | Giá trị xác minh |
|---|---|
| Input | (96, 96, 1) |
| conv1/kernel | (3, 3, 1, 8) |
| conv1/bias | (8,) |
| Output conv1 | (94, 94, 8) |
| Phép MAC | 636.192 |

Đây là xác minh từ tệp mô hình H5, chưa phải số liệu đo trên FPGA.

# Tổng kết Lab 03

- Nhóm tự thiết kế Tiny CNN bằng Keras Expert Mode, cải tiến lần lượt từ V1 đến V5.
- Mô hình V5 có 4 khối Conv2D và dùng đầu vào ảnh xám 96 × 96.
- Kết quả Edge Impulse: **Validation INT8 95,9%**; **Test INT8 93,07%**.
- Đã xuất H5, TFLite Float32, TFLite INT8 và xác minh trọng số Conv1 phục vụ Lab 04.

# Câu hỏi để giảng lại cho người học

- Vì sao phải dùng Validation trong quá trình huấn luyện, thay vì Test?
- Dấu hiệu nào ở V3 khiến nhóm nhận ra hiện tượng overfitting?
- Vì sao Conv1 của V5 cần giữ dạng 8 bộ lọc 3 × 3 và tách ReLU?
- Sự khác nhau giữa Validation Accuracy 95,9% và Test Accuracy 93,07% là gì?