LAB 02

Chuẩn bị dữ liệu MRI và cấu hình Edge Impulse

Làm sạch dữ liệu · Phân chia Train/Test · Thiết lập xử lý ảnh

Bài giảng từ báo cáo thực hành Lab 02

Nội dung bài học

- Hiểu bộ dữ liệu BRISC và sự khác nhau giữa phân loại – phân vùng ảnh.
- Kiểm tra và làm sạch dữ liệu trước khi học máy.
- Đưa tập Training / Test lên Edge Impulse đúng cách.
- Thiết lập Impulse, xử lý Grayscale và sinh đặc trưng.

Chọn đúng bài toán: phân loại ảnh MRI

- **Classification**: một ảnh được dự đoán thuộc một trong bốn nhãn.
- **Segmentation**: xác định vùng ảnh hay từng điểm ảnh của đối tượng.
- Dự án dùng thư mục **classification_task** trong brisc2025.zip; không dùng **segmentation_task**.

Bốn nhãn: glioma · meningioma · no_tumor · pituitary

Đây là bài toán phân loại ảnh MRI, không phải hệ thống xác định ranh giới khối u.

Dữ liệu ban đầu có bao nhiêu ảnh?

Lớp ảnh	Training	Test	Tổng
Glioma	1.147	254	1.401
Meningioma	1.329	306	1.635
No tumor	1.067	140	1.207
Pituitary	1.457	300	1.757
Tổng	5.000	1.000	6.000

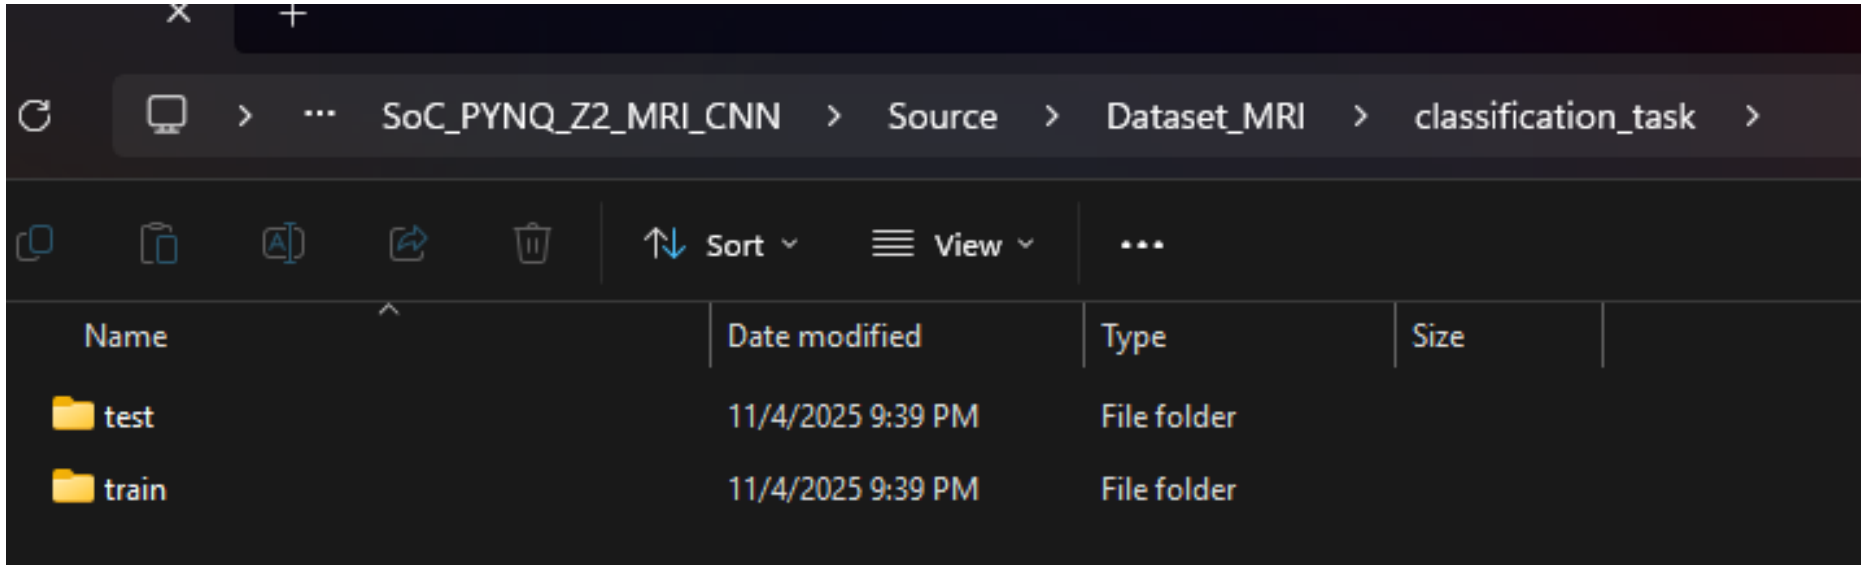
Số lượng trước khi loại ảnh trùng, theo báo cáo Lab 02.

Vì sao phải tách Training và Test?

- **Training**: dữ liệu dùng để mạng CNN học các tham số.
- **Test**: dữ liệu giữ riêng để kiểm tra khả năng dự đoán trên ảnh chưa dùng để học.
- Nếu ảnh giống hệt xuất hiện ở cả Training và Test, kết quả đánh giá có thể quá lạc quan.
- Vì vậy, phải kiểm tra ảnh trùng **trước khi huấn luyện**.

Giải nén dữ liệu vào thư mục Source

– Từ **brisc2025.zip**, giải nén **classification_task** vào thư mục Dataset_MRI trong Source.



Ảnh gốc trong Lab 02: hai tập train và test được lưu riêng.

Giữ nguyên tập ZIP ban đầu để có thể khôi phục dữ liệu khi cần.

SHA-256 dùng để tìm ảnh trùng như thế nào?

- Trước tiên, trên PC chạy **python --version**; Lab 02 ghi nhận **Python 3.14.6**.
- **SHA-256** là hàm băm tạo ra chuỗi đại diện cho nội dung của một tệp.
- Nếu hai ảnh có cùng nội dung tệp, chúng có cùng giá trị SHA-256.
- Phép kiểm tra này **không phát hiện được ảnh gần giống** nếu dữ liệu tệp khác nhau.

Quét ảnh trùng bằng Python

Trích đoạn mã cốt lõi trong check_duplicates.py của Lab 02.

```
from pathlib import Path
from collections import defaultdict
import hashlib


groups = defaultdict(list)
for split in ["train", "test"]:
    for image in (dataset / split).rglob("*.jpg"):
        with image.open("rb") as f:
            digest = hashlib.file_digest(f, "sha256").hexdigest()
        groups[digest].append(image)
```

Biến dataset được khai báo trước đó, trỏ tới thư mục classification_task.

Kết quả phát hiện ảnh trùng

46

nhóm có ảnh trùng

50

ảnh dư thừa

7

nhóm trùng cả Train/Test

Ý nghĩa: nếu đưa nguyên bộ dữ liệu lên nền tảng huấn luyện, các ảnh trùng giữa hai tập có nguy cơ làm sai lệch kết quả đánh giá.

Xem trước trước khi xóa ảnh trùng

- Với mỗi nhóm ảnh cùng mã SHA-256, kiểm tra nhãn của các tệp.
- Nếu một nhóm xuất hiện **nhãn khác nhau**, không tự động xóa.
- Nếu nhãn thống nhất, ưu tiên giữ bản trong **Test** và giữ một ảnh đại diện.
- Sinh **duplicate_preview.txt** để xem danh sách trước khi thay đổi dữ liệu.

Kết quả xem trước: đề xuất xóa 50 ảnh; số nhóm xung đột nhãn = 0.

Xóa có xác nhận, không xóa tùy ý

Báo cáo sử dụng xác nhận thủ công và điều kiện bảo vệ trước khi xóa tệp.

```
if conflicts or len(to_delete) != 50:
    raise SystemExit("Dataset changed. Deletion cancelled.")
confirm = input("Type DELETE 50 to confirm: ").strip()
if confirm == "DELETE 50":
    for image in to_delete:
        image.unlink()
```

Trích đoạn thể hiện điều kiện xác nhận; phiên bản gốc còn ghi log deleted_duplicates.txt.

Lưu ý: thao tác xóa này không chuyển ảnh vào Recycle Bin; ZIP gốc được giữ lại.

Sau làm sạch: kiểm tra lại dữ liệu

Chỉ tiêu	Kết quả
Training	4.955 ảnh
Test	995 ảnh
Tổng	5.950 ảnh
Nhóm trùng SHA-256	0
Nhóm trùng Train/Test	0

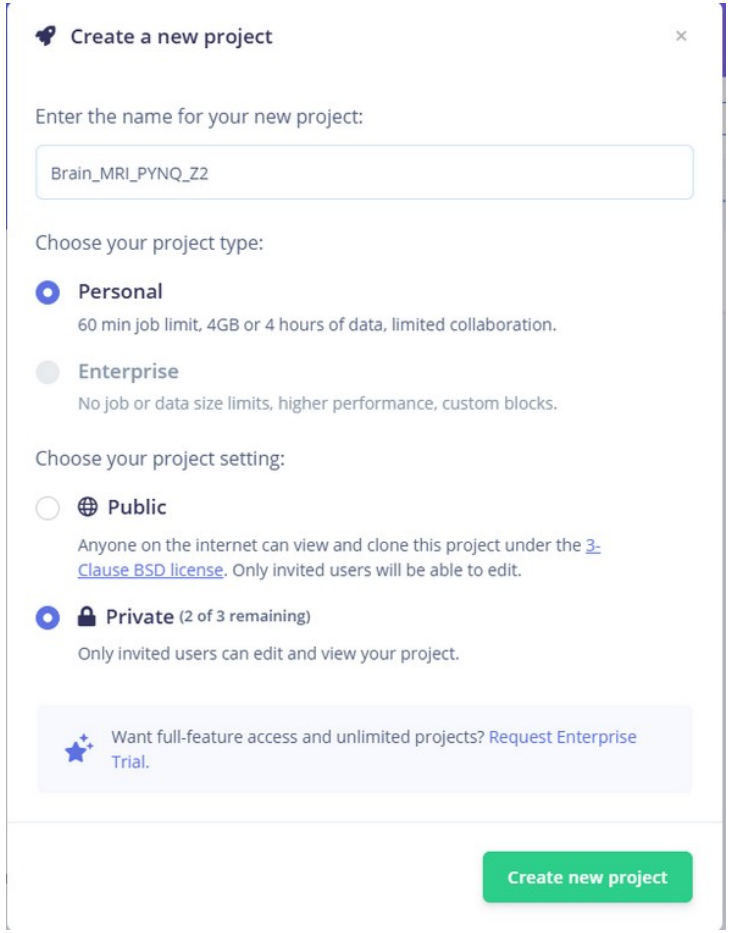
Đây là kết quả xác minh ảnh trùng hoàn toàn theo SHA-256.

Cần hiểu đúng kết quả làm sạch

- Đã loại 50 ảnh dư thừa và kiểm tra không còn nhóm trùng SHA-256.
- **Chưa kiểm tra** các ảnh gần trùng khác mã băm.
- **Chưa chứng minh** ảnh của cùng một bệnh nhân được tách hoàn toàn giữa Train và Test.
- Vì vậy, chỉ kết luận đúng những gì phép kiểm tra dữ liệu thực sự xác nhận.

Tạo dự án trên Edge Impulse

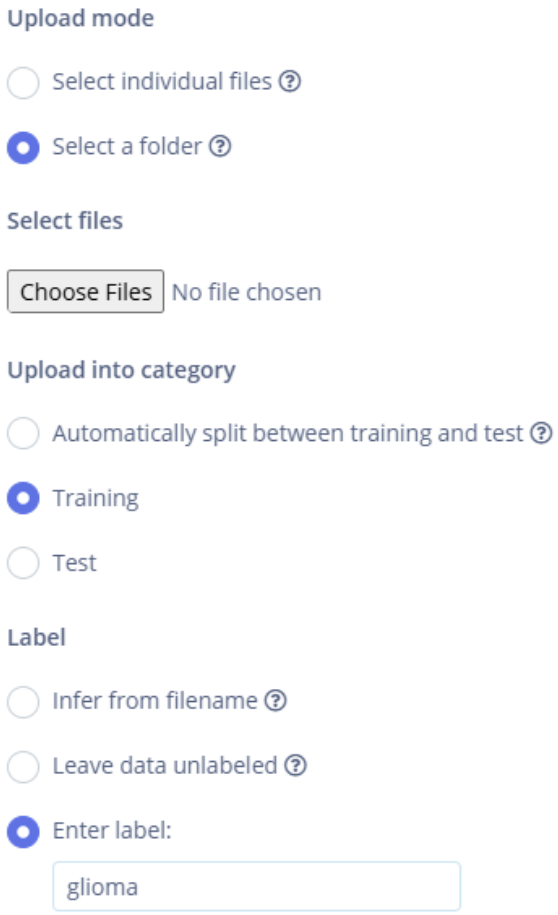
- Truy cập **studio.edgeimpulse.com** và tạo project mới.
- Tên dự án trong Lab 02: **Brain_MRI_PYNQ_Z2**.
- Chọn **Personal, Private** và **One label per data item**.



Ảnh gốc giao diện Create a new project.

Tải ảnh Glioma vào Training

- Data acquisition → Dataset → Add data.
- Upload mode: **Select a folder**.
- Upload into category: **Training**.
- Label: **glioma**; chọn thư mục train/glioma.
- Khi hỏi Object Detection, chọn **No**.



Giao diện upload trong Lab 02; 1.147 ảnh Glioma được tải lên thành công.

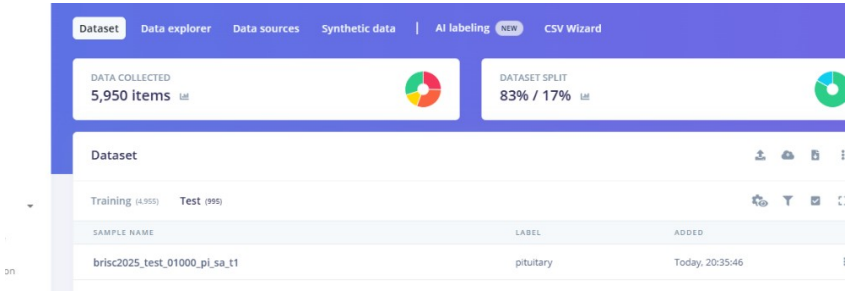
Tải đủ bốn lớp Training

Nhãn	Số ảnh
glioma	1.147
meningioma	1.310
no_tumor	1.058
pituitary	1.440
Tổng Training	4.955

Không chọn “Automatically split between training and test”.

Tải Test riêng và xác nhận tổng số

Nhãn	Test
glioma	253
meningioma	303
no_tumor	139
pituitary	300
Tổng Test	995



Tổng dữ liệu: **5.950** ảnh; Training: **4.955**; Test: **995**.

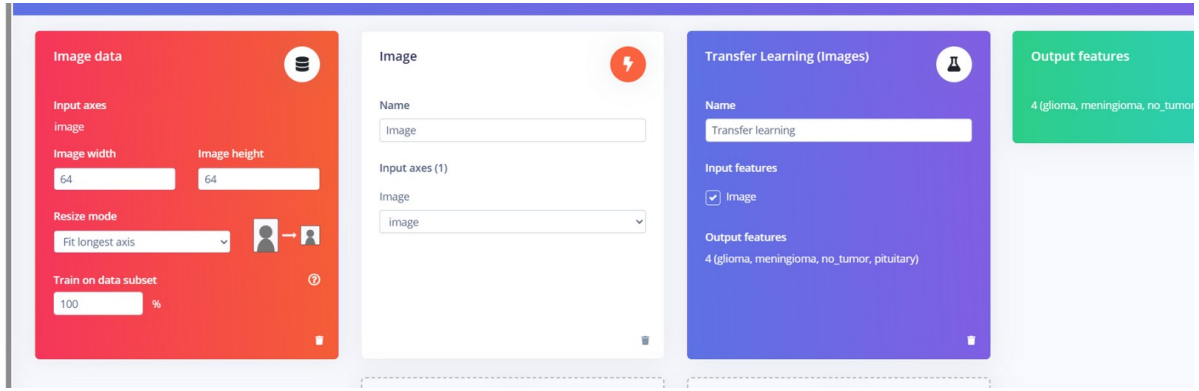
Tỷ lệ trên giao diện xấp xỉ 83% / 17%.

Thiết lập Impulse ban đầu

Ở Lab 02, cấu hình khởi đầu trên Edge Impulse như sau:

- Ảnh **64 × 64**, Resize mode = **Fit longest axis**.
- Train on data subset = **100%**.

Image data → Image Processing → Transfer Learning (Images)

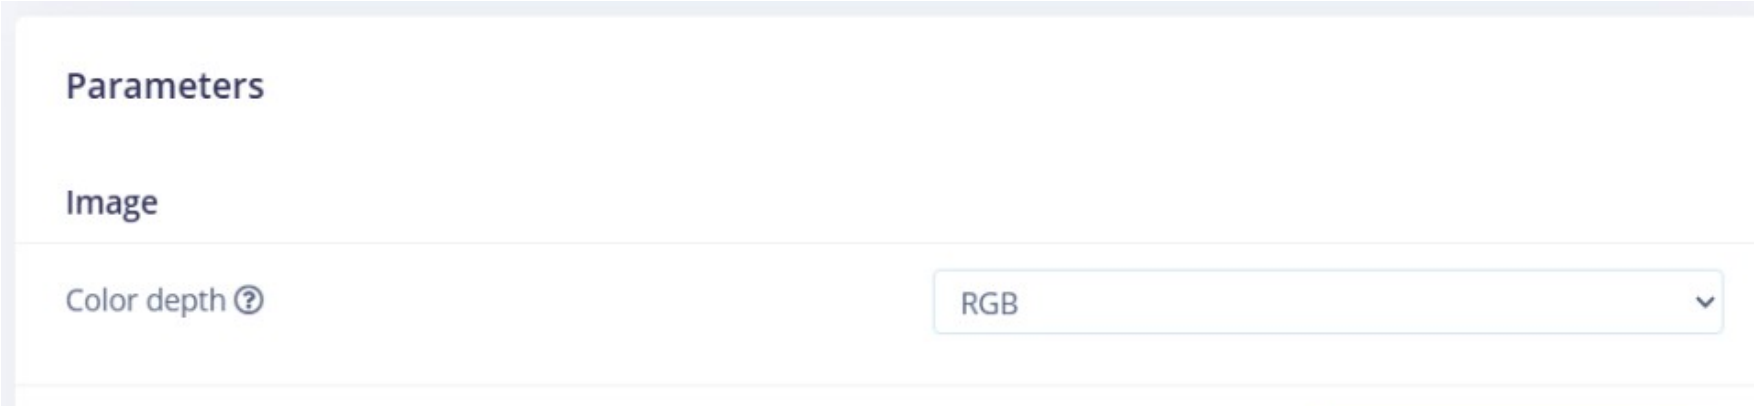


Đây là cấu trúc ban đầu, chưa phải Tiny CNN đã huấn luyện.

Vì sao chọn Grayscale?

Ảnh xám chỉ có một kênh; giúp mạng nhận đầu vào thống nhất và giảm số giá trị phải xử lý so với RGB.

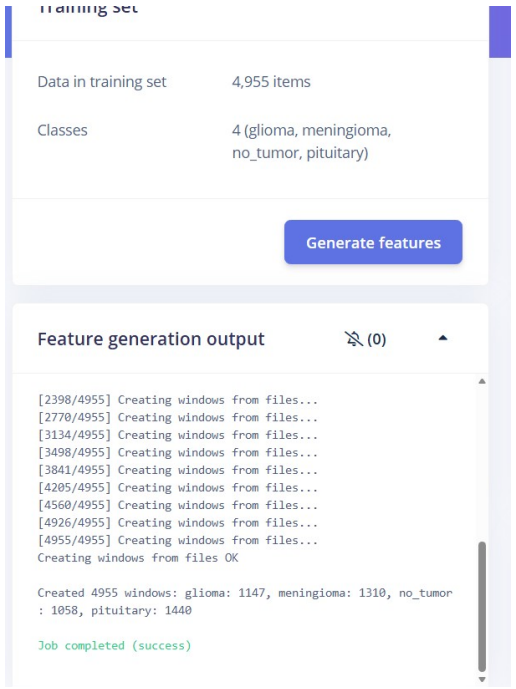
64 × 64 × 1 = 4.096 giá trị đầu vào

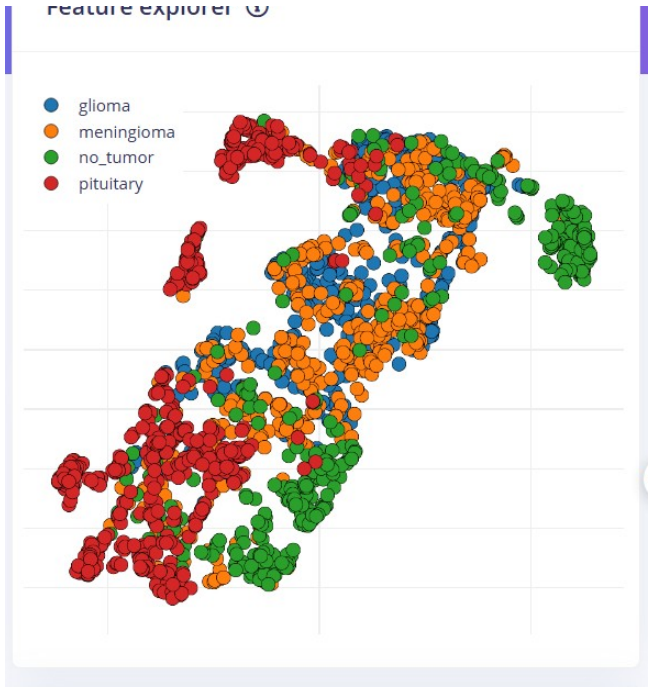


Ảnh trong báo cáo chụp trước khi đổi Color depth từ RGB sang Grayscale.

Generate Features: kiểm tra dữ liệu đã sẵn sàng

Chọn **Generate features**. Đợi thông báo **Job completed (success)** và mở Feature explorer.





4.955 cửa sổ Training được xử lý thành công; biểu đồ thể hiện bốn nhãn.

Feature Explorer không phải Accuracy

- Biểu đồ Feature Explorer là cách **quan sát phân bố đặc trưng** của dữ liệu.
- Nó **không đo độ chính xác phân loại** của mô hình CNN.
- Các số **7 ms** và **4 KB** trên Edge Impulse không phải thời gian hay bộ nhớ đo trên PYNQ-Z2.
- Từ đây, dữ liệu đã sẵn sàng để chuyển sang nội dung huấn luyện mô hình của Lab 03.

Tổng kết Lab 02

- Chọn đúng bộ dữ liệu classification_task và xác định bốn nhãn MRI.
- Kiểm tra trùng SHA-256, loại 50 ảnh, còn 4.955 Training và 995 Test.
- Tải dữ liệu lên Edge Impulse mà không trộn lại hai tập.
- Thiết lập Impulse ban đầu, chọn Grayscale và sinh đặc trưng thành công.

Câu hỏi để tự thuyết trình

Vì sao phải xử lý ảnh trùng trước khi đánh giá mô hình? Vì sao 4.955 Feature Windows không phải 4.955 dự đoán đúng?