TRƯỜNG ĐẠI HỌC
CÔNG NGHỆ KỸ THUẬT TP. HỒ CHÍ MINH
HCM·UTE
HCMC University of Technology and Engineering

BÁO CÁO CUỐI KỲ

THIẾT KẾ VÀ ĐÁNH GIÁ BỘ TĂNG TỐC PHẦN CỨNG CHO MẠNG NƠ-RON TÍCH CHẬP LƯỢNG TỬ HÓA INT8 TRONG PHÂN LOẠI ẢNH MRI NÃO TRÊN SOC PYNQ-Z2

Môn học: Thiết kế SoC - SOCD334264

Mã lớp học phần: 261SOCD334264_01

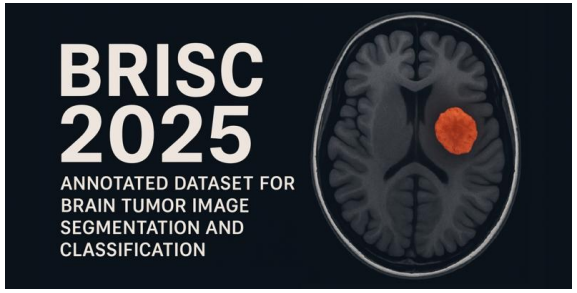
GVHD: TS. Trương Quang Phúc

Các thành viên thực hiện:

Lê Quốc Khánh	Nguyễn Mai Trung Dũng
MSSV: 24161276	**MSSV:** 24161206
Đặng Quang Được	Nguyễn Hữu Đức
MSSV: 24161217	**MSSV:** 24161221
Lê Minh Hải	Lã Phan Ân Kỳ
MSSV: 24161225	**MSSV:** 24161294

BỘ DỮ LIỆU MRI

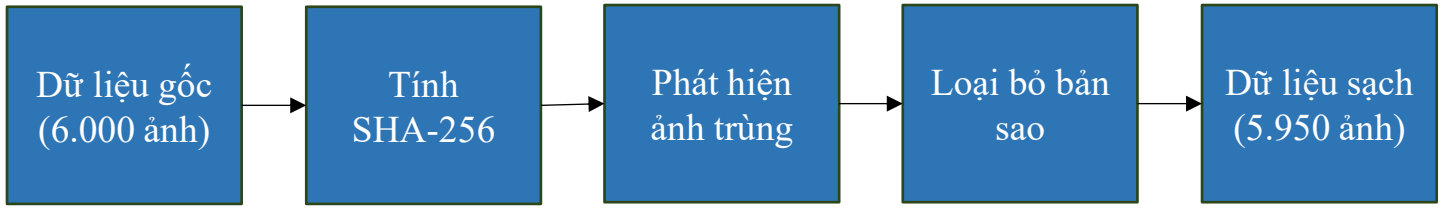
NGUỒN DỮ LIỆU: BRISC 2025 *(Brain Tumor MRI Dataset for Segmentation and Classification)*



- Được giới thiệu bởi Fateh và cộng sự, công bố trên Scientific Data *(2026)*.
- Gồm **6.000** ảnh MRI não T1-weighted, thuộc ba mặt phẳng Axial, Coronal và Sagittal.
- Bốn nhóm: Glioma, Meningioma, No tumor và Pituitary.
- Sử dụng nhánh ***classification_task*** từ bộ dữ liệu công khai trên Kaggle.
- Sau khi loại bỏ **50** ảnh trùng: còn **5.950** ảnh *(4.955 Training và 995 Test)*.

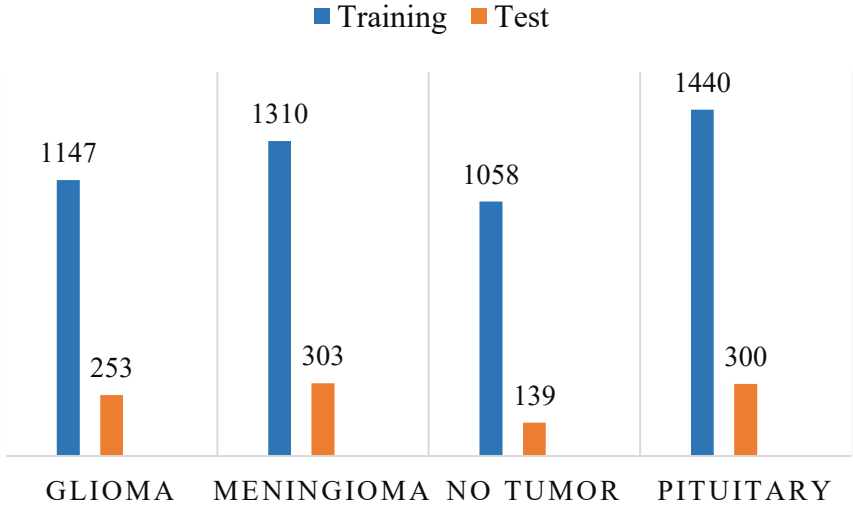
KỸ THUẬT LÀM SẠCH DỮ LIỆU MRI

Phương pháp: sử dụng thuật toán băm SHA-256 để phát hiện và loại bỏ các tệp ảnh trùng lặp, đồng thời kiểm tra trùng lặp giữa tập Training và Test.

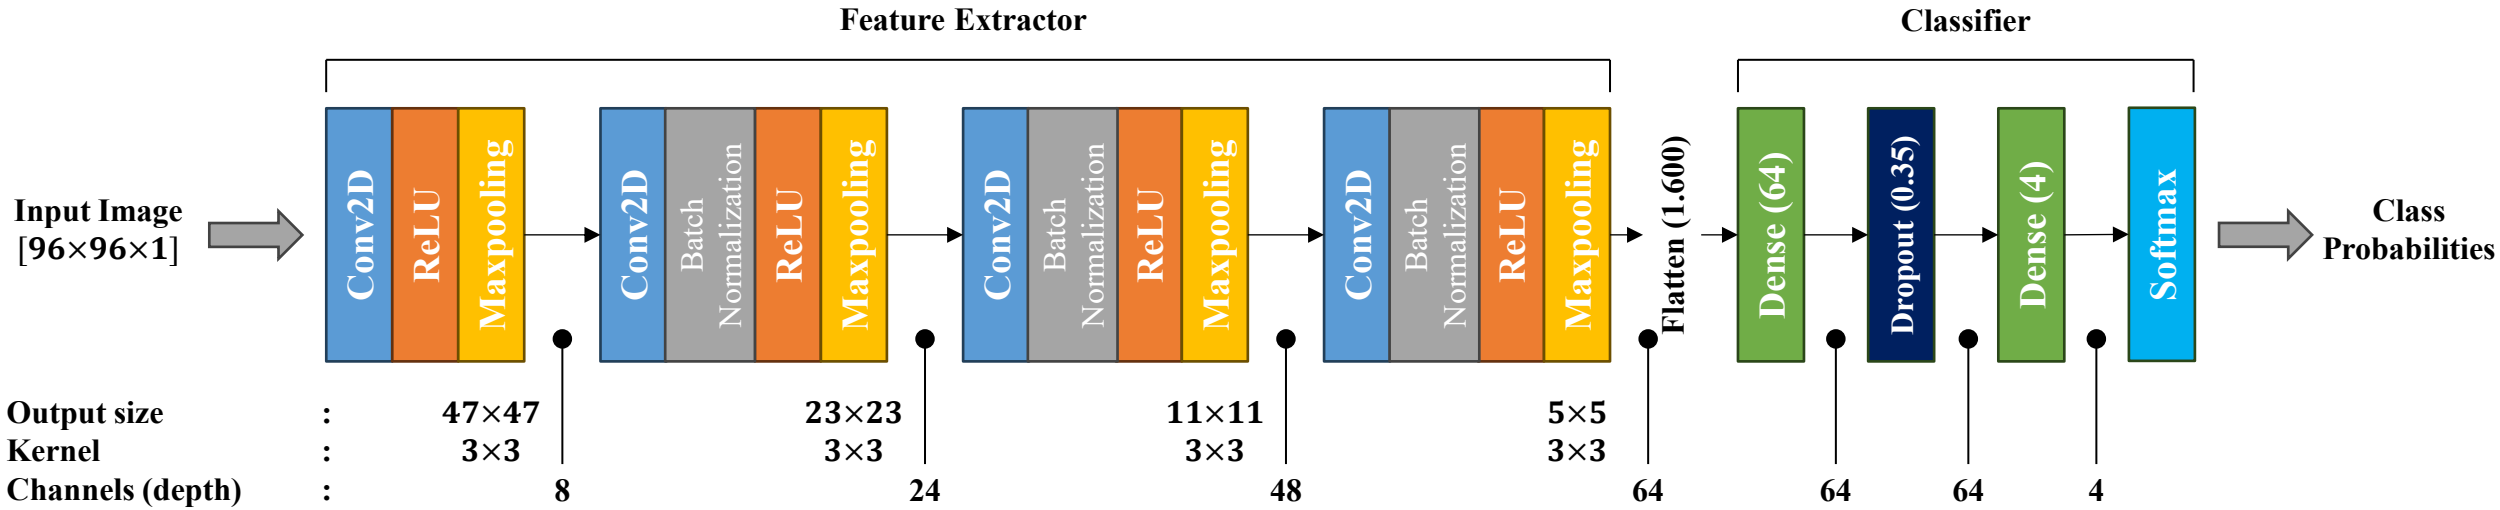


Kết quả: Phát hiện *46 nhóm ảnh trùng* và loại bỏ *50 ảnh dư thừa*.

PHÂN BỐ TẬP DỮ LIỆU MRI SAU KHI LÀM SẠCH



KIẾN TRÚC MẠNG CNN VÀ KẾT QUẢ HUẤN LUYỆN



THIẾT LẬP HUẤN LUYỆN VÀ KẾT QUẢ XÁC THỰC

Thông số huấn luyện	Giá trị
Optimizer	Adam
Learning rate	0.0003
Batch size	32
Epochs tối đa	80
Validation	991 ảnh

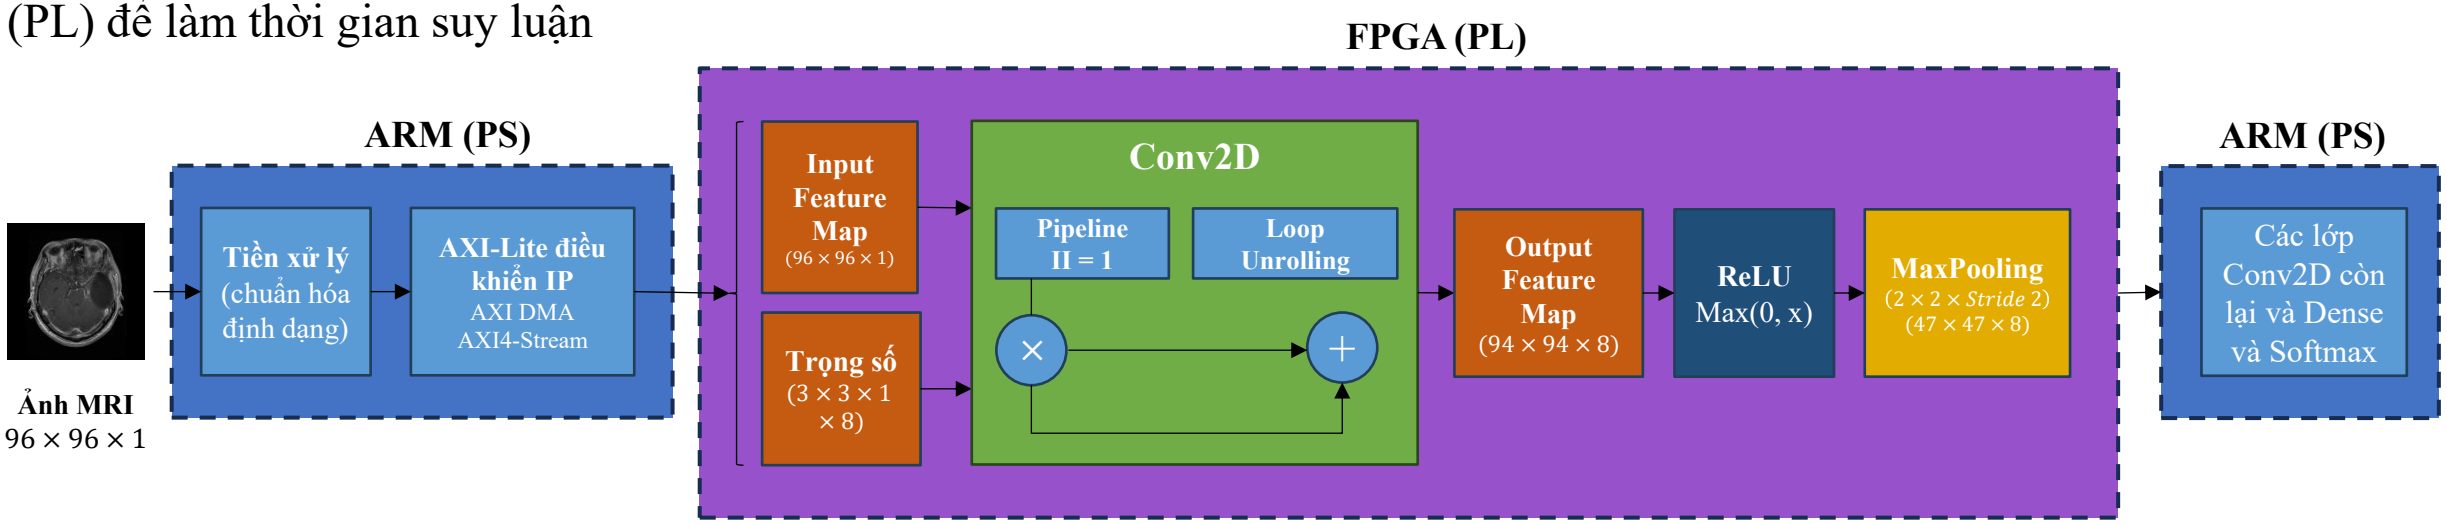
Confusion matrix (validation set)

	GLIOMA	MENINGIOMA	NO_TUMOR	PITUITARY
GLIOMA	**95.5%**	4.5%	0%	0%
MENINGIOMA	3.7%	**91.1%**	2.6%	2.6%
NO_TUMOR	0%	2.5%	**97.5%**	0%
PITUITARY	0%	0.3%	0.3%	**99.3%**
F1 SCORE	0.95	0.93	0.97	0.98

Kết quả trên tập Validation	Giá trị
Validation accuracy	95.9 %
Validation loss	0.15

THIẾT KẾ BỘ TĂNG TỐC CHO LỚP CONV2D ĐẦU TIÊN

Thuật toán tăng tốc: triển khai lớp Conv2D đầu tiên của CNN trên FPGA bằng Vitis HLS, kết hợp ARM (PS) và FPGA (PL) để làm thời gian suy luận



Estimated Quality of Results

Timing Estimate

TARGET	WITH UNCERTAINTY	ESTIMATED
10.00 ns	7.30 ns	6.955 ns

Performance & Resource Estimates

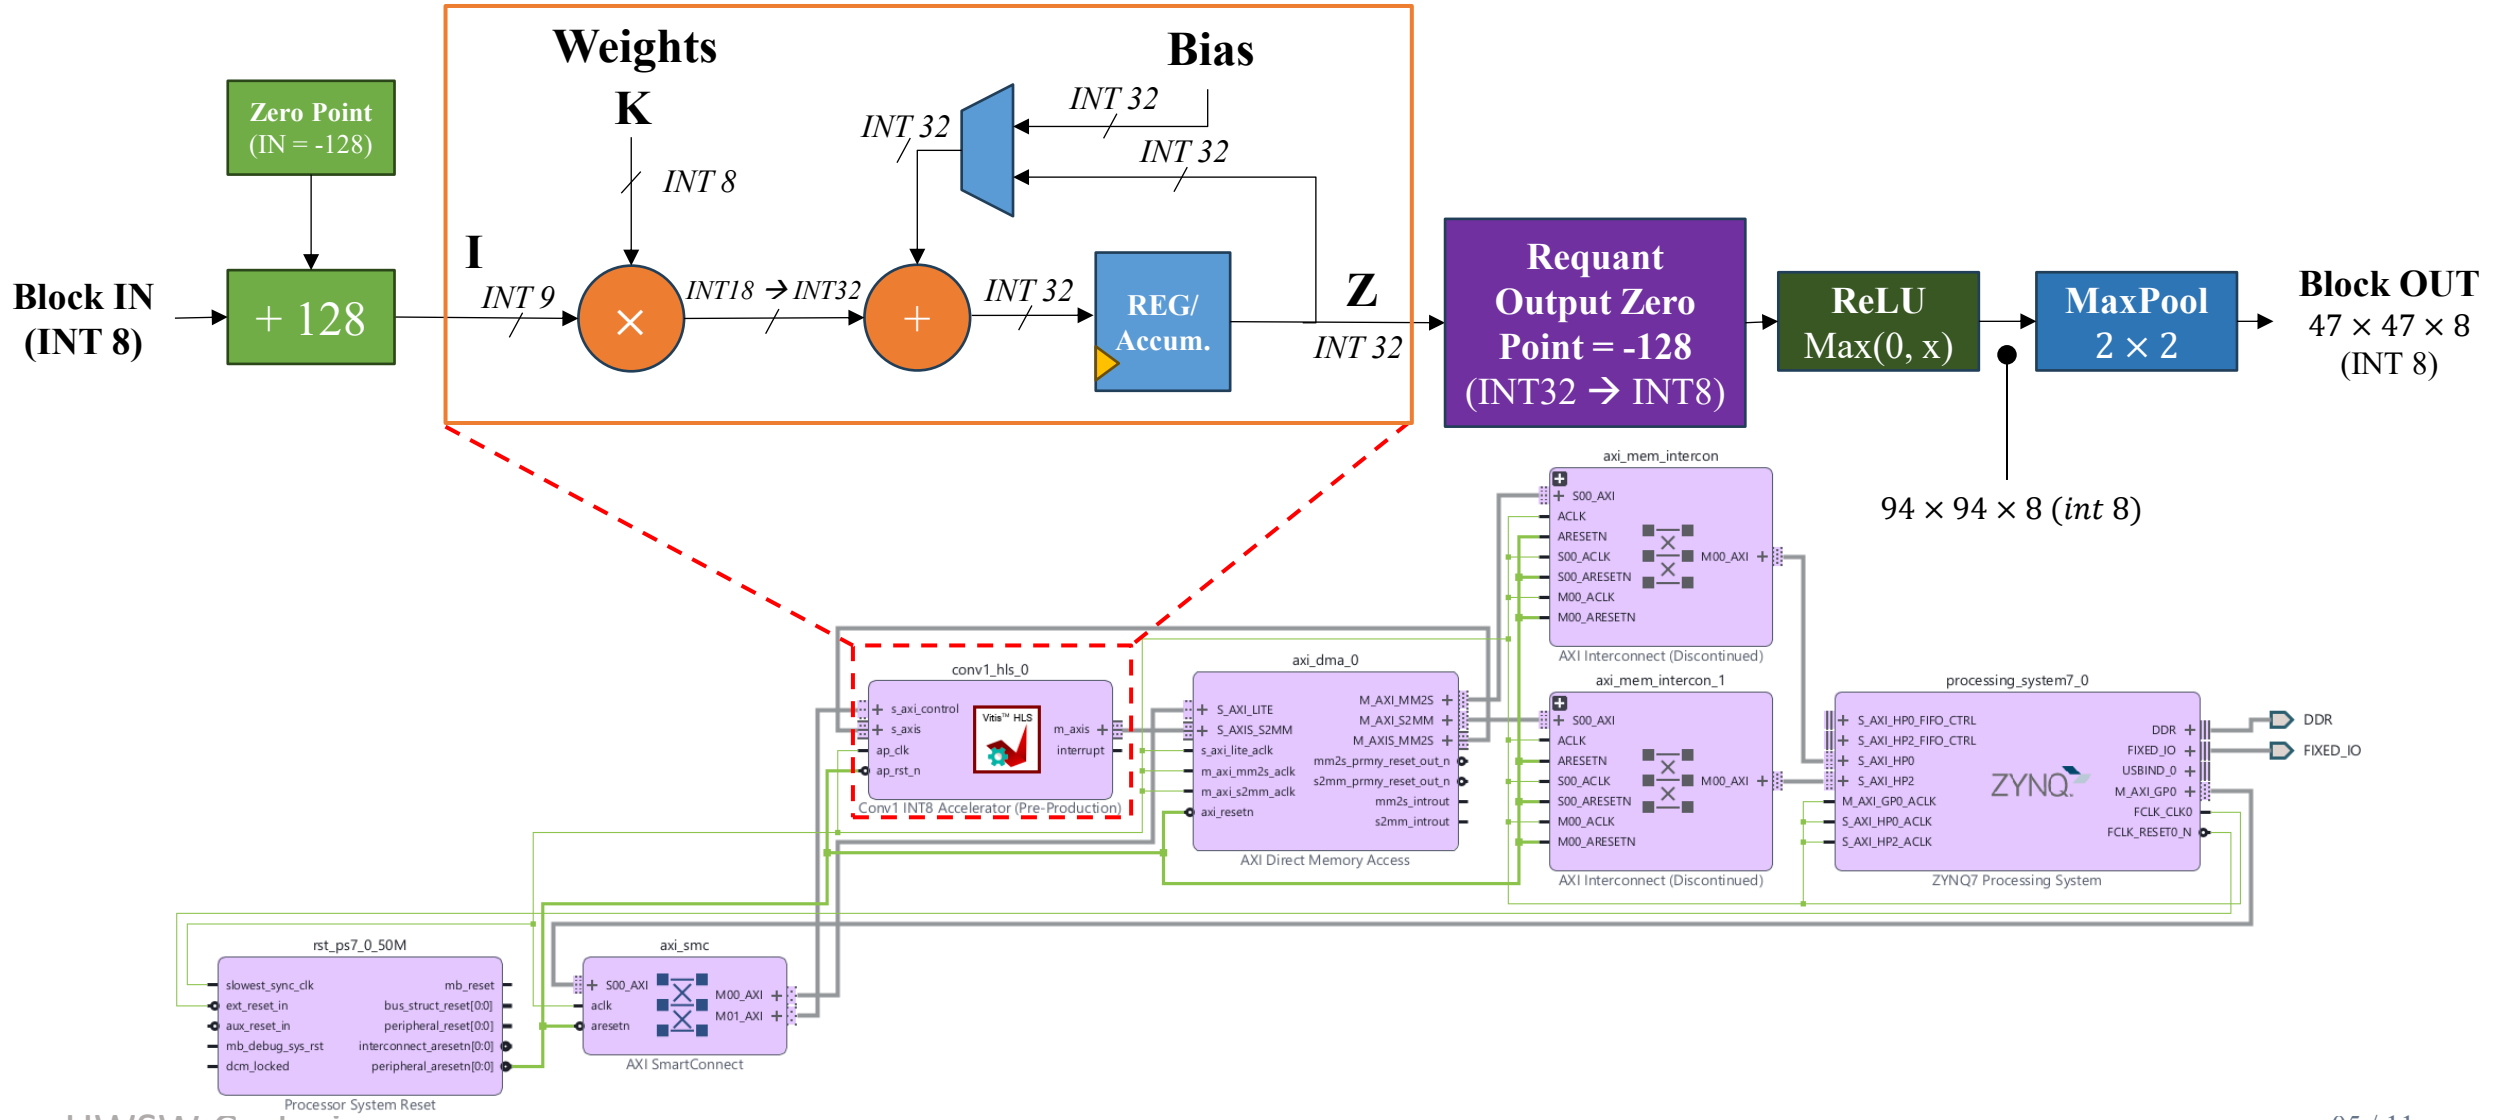
Modules

DULES & LOOPS	LATENCY(NS)	ITERATION LATENCY	INTERVAL	TRIP COUNT	PIPELINED	STRUCTURE	BRAM	DSP
conv1_hls (1)	9.230E4		9,226		loop auto-rewind s	function	6	58
ROW_LOOP_COL_LOOP	9.228E4	14	1	9,216	yes	loop		

Ý tưởng tăng tốc

- Triển khai Conv1, ReLU và MaxPooling trên FPGA bằng Vitis HLS.
- Áp dụng Pipeline với II = 1 để tăng thông lượng xử lý.
- Sử dụng AXI DMA/AXI4-Stream truyền dữ liệu và AXI4-Lite điều khiển IP.
- Kết quả HLS: chu kỳ ước lượng 6.955 ns, sử dụng 58 DSP và 6 BRAM.

BLOCK DESIGN TRÊN VIVADO



ƯỚC LƯỢNG TÀI NGUYÊN VÀ TIMING TRÊN VIVADO

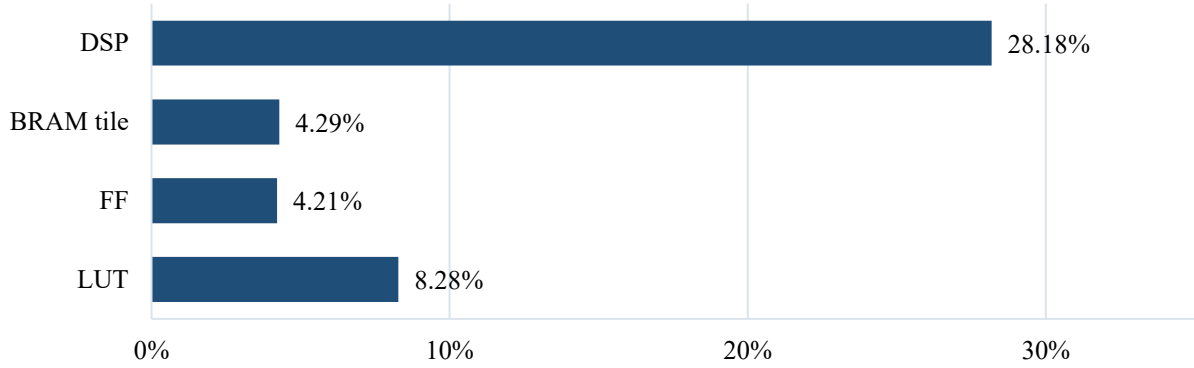
1. MỨC SỬ DỤNG TÀI NGUYÊN FPGA

- *LUT (8,28%)*: Thực hiện các hàm logic tổ hợp.
- *FF (4,21%)*: Các thanh ghi lưu trữ dữ liệu và trạng thái.
- *BRAM (4,29%):* Bộ nhớ nội FPGA, lưu dữ liệu trung gian.
- *DSP (28,18%):* Khối tính toán số học, đặc biệt là phép nhân - cộng (MAC).

2. PHÂN TÍCH TIMING

- *WNS = +1,355 ns*: Đáp ứng yêu cầu Setup Timing.
- *WHS = +0,047 ns*: Đáp ứng yêu cầu Hold Timing.
- *TNS = THS = 0 ns*: Không có tổng độ trễ vi phạm được báo cáo.
- *Failing Endpoints = 0*: Không có điểm kết thúc đường truyền vi phạm Timing.

→ **Nhận xét:** Thiết kế đáp ứng các ràng buộc Timing và còn dư tài nguyên FPGA, trong đó DSP có tỷ lệ sử dụng cao nhất (28,18%).



Setup

Worst Negative Slack (WNS)	1.355 ns
Total Negative Slack (TNS)	0.000 ns
Number of Failing Endpoints	0
Total Number of Endpoints	14386

Hold

Worst Hold Slack (WHS)	0.047 ns
Total Hold Slack (THS)	0.000 ns
Number of Failing Endpoints	0
Total Number of Endpoints	14386

Name	Slice LUTs (53200)	Slice Registers (106400)	F7 Muxes (26600)	Block RAM Tile (140)	DSPs (220)	Bonded IOPADs (130)	BUFGCTRL (32)
conv1_system_wrapper	4405	4484	13	6	62	130	1
conv1_system_i (conv1_system)	4405	4484	13	6	62	0	1
axi_dma_0 (conv1_system_axi_	1650	2155	13	3	0	0	0
axi_mem_intercon (conv1_syste	46	85	0	0	0	0	0
axi_mem_intercon_1 (conv1_sy	196	203	0	0	0	0	0
axi_smc (conv1_system_axi_sm	404	441	0	0	0	0	0
conv1_hls_0 (conv1_system_co	2070	1567	0	3	62	0	0

KIỂM CHỨNG TRÊN PYNQ-Z2

KIỂM THỬ 01 ẢNH MRI QUA **30 LẦN ĐO** ĐỂ SO SÁNH

CHẠY ARM THUẦN

- Chạy toàn bộ mô hình Tflite INT8 trên CPU (ARM)
- Làm mốc so sánh về độ trễ

KẾT HỢP CẢ ARM VÀ FPGA

- DMA gửi ảnh từ DDR đến IP Conv2D đầu tiên trên FPGA
- FPGA xử lý khối đầu (Conv2D đầu tiên + ReLU + MaxPool)
- ARM tiếp tục chạy phần còn lại của mô hình

KHỚP TOÀN BỘ ĐẦU RA INT8 Ở CẢ 30 LƯỢT THỬ

Kết quả: mô hình kết hợp cả ARM và FPGA cho đầu ra chính xác và tăng tốc 1,309x so với ARM THUẦN

```
Warming up...
Benchmarking 30 runs...

=== MRI CLASSIFICATION ===
Image: brisc2025_test_00023_gl_ax_t1.j
Predicted class index: 0
Scores: [0.9961 0.     0.     0.    ]
ARM output: [ 127 -128 -128 -128]
Hybrid output: [ 127 -128 -128 -128]
All outputs match: True

=== PERFORMANCE (MEDIAN) ===
Measured runs: 30
ARM only        : 23.626 ms
FPGA + DMA      : 1.507 ms
ARM tail        : 16.554 ms
ARM + FPGA      : 18.055 ms
Speedup         : 1.309x

PASS: Hybrid CNN verified
```

ĐÁNH GIÁ ĐỘ CHÍNH XÁC VÀ KIỂM CHỨNG ĐẦU RA

KIỂM THỬ XEM **MÔ HÌNH CNN NHẬN DIỆN ẢNH MRI** CÓ CHÍNH XÁC **KHÔNG KHI CHUYỂN CONV2D ĐẦU TIÊN SANG FPGA**

92,66%

922 / 995 ảnh đúng

0,9194

Macro F1 của bốn lớp

995 / 995

Tensor cuối ARM và Hybrid khớp

Thật \ Đoán	Glioma	Mening.	No tumor	Pituitary
Glioma	244	7	0	2
Meningioma	17	264	12	10
No tumor	3	13	117	6
Pituitary	1	2	0	297

Recall thấp nhất: No tumor 84,17%

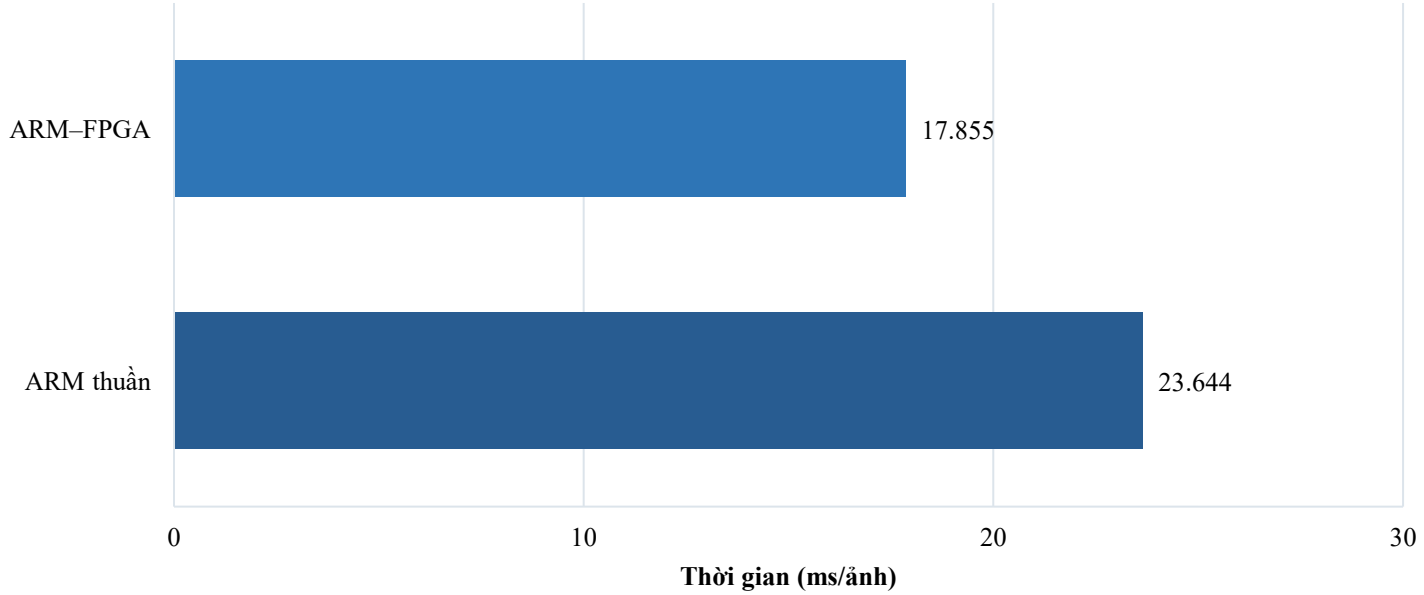
```
Total images: 995
Identical ARM/Hybrid outputs: 995/995
ARM accuracy: 92.66%
Hybrid accuracy: 92.66%
ARM macro F1: 0.9194
Hybrid macro F1: 0.9194
```

73 ảnh sai ở cả hai cấu hình

→ *Các cả ảnh được phân loại sai giống nhau trên cả ARM và khi kết hợp ARM và FPGA*

ĐÁNH GIÁ HIỆU NĂNG VÀ MỨC TĂNG TỐC ARM-FPGA

Kiểm thử trên **toàn bộ 995 ảnh MRI thuộc tập Test**, thay vì chỉ một ảnh đơn lẻ. Thực hiện 5 lượt warm-up, đo thời gian suy luận một lần cho mỗi ảnh ở từng cấu hình (ARM thuần và ARM-FPGA), đồng thời đảo thứ tự chạy để giảm sai lệch khi so sánh.




```
ARM only: 23.644 ms
FPGA + DMA: 1.452 ms
ARM tail: 16.431 ms
ARM + FPGA: 17.855 ms
Speedup (ratio of medians): 1.324x
Speedup (total inference time): 1.324x
```

1,324×

Giảm 5,789 ms mỗi ảnh

Tương đương 24,48%

FPGA + DMA: 1,452 ms

ARM tail: 16,431 ms

KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

ĐÃ CHỨNG MINH

1. Hệ thống ARM-FPGA chạy trên board thật
2. Giữ đầu ra cuối giống ARM trên 995 ảnh kiểm thử
3. Tăng tốc suy luận 1,324× với accuracy 92,66%

GIỚI HẠN

1. Chưa đánh giá độc lập theo bệnh nhân
2. Tiền xử lý khác Edge Impulse
3. Recall lớp No tumor còn thấp: 84,17%.
4. Chưa kiểm chứng trực tiếp tensor sau Pool1.

HƯỚNG TIẾP THEO

1. Mở rộng tăng tốc Conv2–Conv4, cân đối tài nguyên FPGA.
2. Tối ưu DMA, đồng bộ và pipeline PS–PL.
3. Chuẩn hóa tiền xử lý, kiểm chứng Pool1 bit-exact.
4. Đo lặp, đánh giá P95 và throughput.

Tham khảo chính: BRISC [1], Google LiteRT INT8 [2], PYNQ DMA [3]

ẢNH NHÓM CÁC THÀNH VIÊN



XIN CẢM ƠN THẦY VÀ CÁC BẠN ĐÃ LẮNG NGHE